CE-2103 · Lección 07

Algoritmos de Compresión

Representar los mismos datos con menos bits



Instituto Tecnológico de Costa Rica · Ingeniería en Computadores

// introducción

¿Qué aprenderemos hoy?

1. Diferenciar la compresión con pérdida y sin pérdida
2. Construir el árbol y los códigos de Huffman
3. Explicar la entropía y el límite de Shannon
4. Aplicar la codificación aritmética a mensajes cortos
5. Comprimir y descomprimir con LZ77, LZ78 y LZW
6. Comparar los algoritmos según sus características

// introducción

¿Qué es comprimir?

1

Datos originales

Un conjunto de bits: texto, imágenes, audio, video.

2

Algoritmo

Reduce la cantidad de bits requeridos para representar los datos.

3

Resultado

Datos comprimidos: ocupan menos espacio en disco y viajan más rápido por la red.

Dos categorías: compresión **con pérdida** (lossy) y **sin pérdida** (lossless).

// tipos de compresión

Con pérdida vs. sin pérdida

Con pérdida (lossy)

- Elimina información innecesaria
- **Irreversible:** el original no se recupera
- Audio, video e imágenes
- Parámetro de calidad: compresión vs. degradación

vs

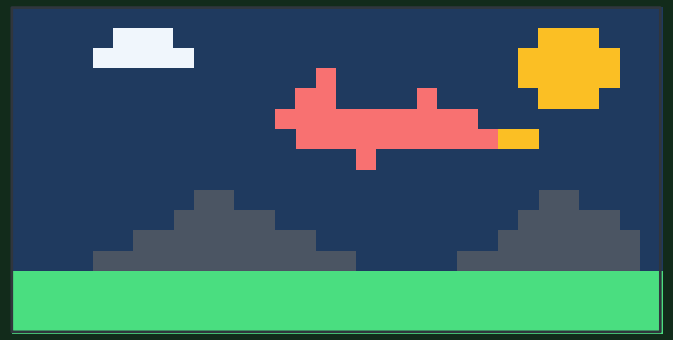
Sin pérdida (lossless)

- Reduce el tamaño sin perder información
- **Reversible:** se recupera el original
- Texto, documentos y bases de datos
- Reemplaza patrones repetidos por códigos más cortos

Ejemplos: **JPEG** y **MP3** (con pérdida) · **ZIP** y **GIF** (sin pérdida).

Con pérdida: el parámetro de calidad

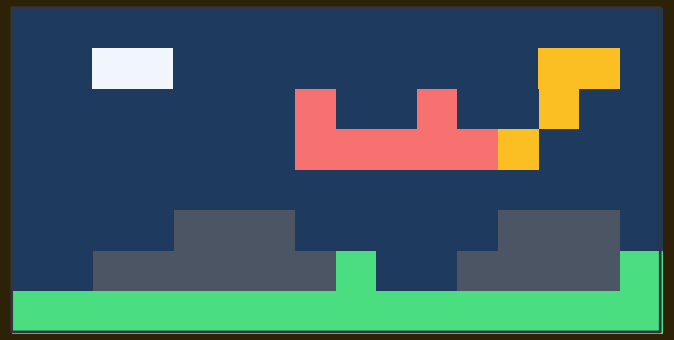
Calidad 50 %



50 %

Se conserva casi todo el detalle.

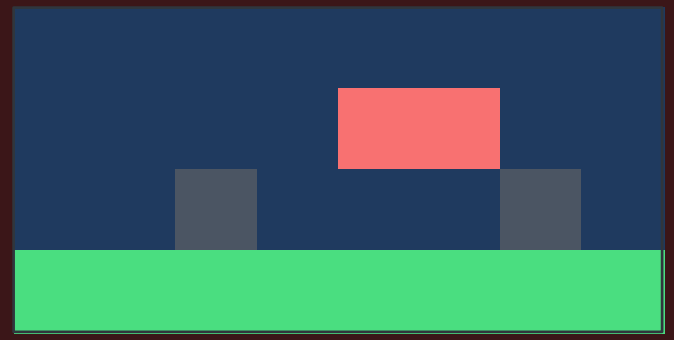
Calidad 33 %



33 %

Se pierde detalle: los bordes se ven escalonados.

Calidad 5 %



5 %

Bloques grandes: ya no se reconocen los detalles.

Un parámetro de calidad equilibra la tasa de compresión y la degradación visible (50 %, 33 %, 5 %).

¿Por qué usar compresión con pérdida?

Original

Alta fidelidad (raw)

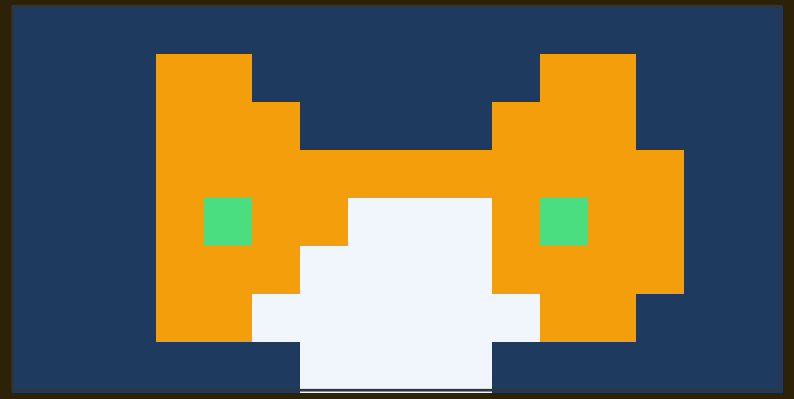


Archivo enorme: conserva todos los detalles.

Compresión con pérdida →

Con pérdida

Compresión lossy



Mucho más pequeño, a cambio de algo de degradación.

Los formatos de alta fidelidad (raw) son enormes: sin compresión lossy, el streaming de audio y video no sería posible.

// tipos de compresión

Percepción de la calidad

Distorsión

Diferencia entre los datos originales y los comprimidos.

Percepción subjetiva

Depende del observador: un audiófilo tolera menos distorsión que una persona promedio.

Fisiología humana

JPEG elimina detalles poco visibles; MP3, sonidos poco audibles.

Los algoritmos **lossy** optimizan la calidad percibida según los atributos fisio-psicológicos del ser humano.

// tipos de compresión

Compresión sin pérdida

Cómo funciona

- Es reversible: se recupera el original
- Usa estadística para hallar patrones repetidos
- Los reemplaza por códigos más cortos
- Ej.: frecuencia de caracteres o de colores

Algoritmos comunes

Huffman **LZW** **LZ77** **LZ78**

RLE **Deflate (ZIP)** **BWT**

*En esta lección: **Huffman**, **LZ77**, **LZ78** y **LZW**.*

> Es la categoría adecuada para texto, documentos y bases de datos, donde no se puede perder información.

// huffman

Huffman: códigos de longitud variable

Desarrollado por David A. Huffman (publicado en 1952). Es un algoritmo de compresión sin pérdida.

Longitud variable

Códigos cortos para los símbolos frecuentes y largos para los poco frecuentes.

Árbol binario

Se construye un árbol que asigna un código a cada símbolo.

Tabla de conversión

Se guarda en el archivo comprimido: es esencial para descomprimir.

> No todos los símbolos necesitan los 8 bits de ASCII: si una letra aparece mucho, conviene darle un código muy corto.

// huffman

El algoritmo en 6 pasos

1. Calcular la **frecuencia** de cada símbolo en el archivo.
2. Crear un **nodo hoja** por símbolo y ordenarlos de menor a mayor frecuencia.
3. **Unir** los dos nodos menores en un padre y reordenar la lista.
4. Repetir el paso 3 hasta que quede **un solo nodo**.
5. Recorrer el árbol: **0** a las ramas izquierdas y **1** a las derechas.
6. Crear la **tabla de conversión** y comprimir el archivo.

// huffman

Ejemplo: frecuencias de los símbolos

Texto original (15 símbolos)

```
bcaadddccacacac
```



Frecuencias

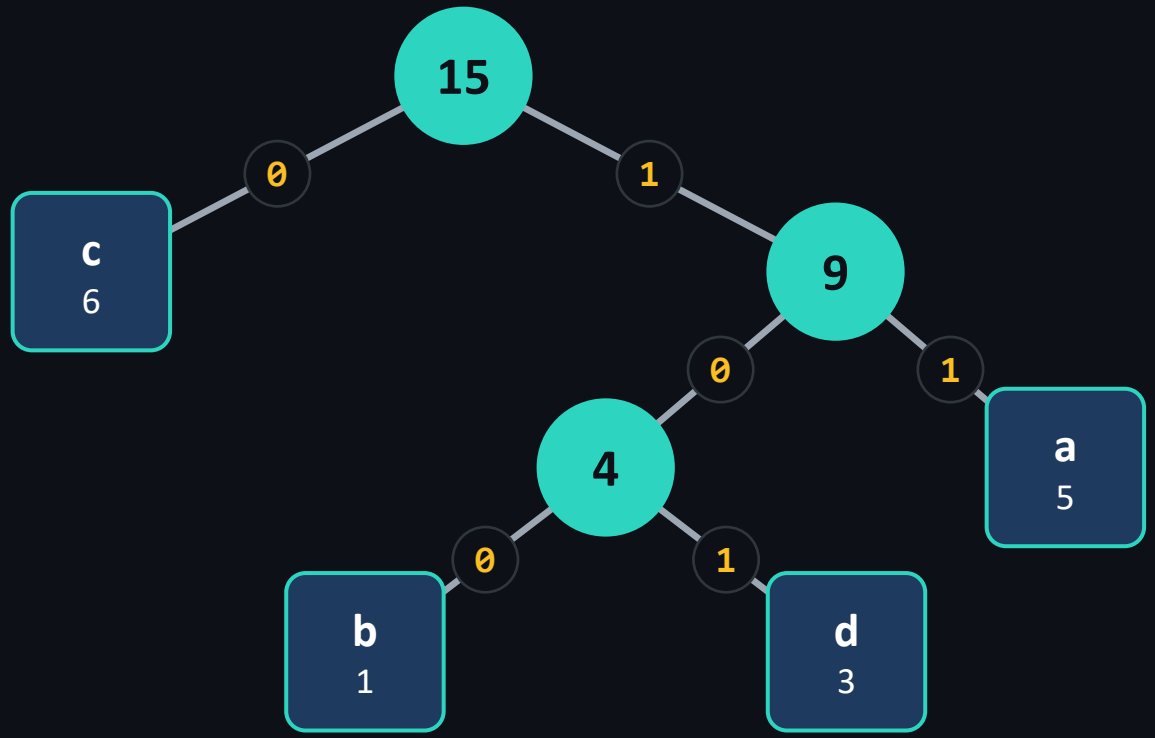
Símbolo	Frecuencia
b	1
c	6
a	5
d	3

En ASCII cada carácter ocupa 8 bits: 8 × 15 = **120 bits** en total.

Construcción del árbol

Inicio		Hojas ordenadas por frecuencia. Se unen las dos menores: **b** y **d**.
Paso 1		El nodo **4** se inserta según su frecuencia. Se unen **4** y **a**.
Paso 2		El nodo **9** queda al final: tiene la mayor frecuencia. Se unen **c** y **9**.
Paso 3		Queda un solo nodo: la **raíz** (15 = total de símbolos).

El árbol y la tabla de conversión

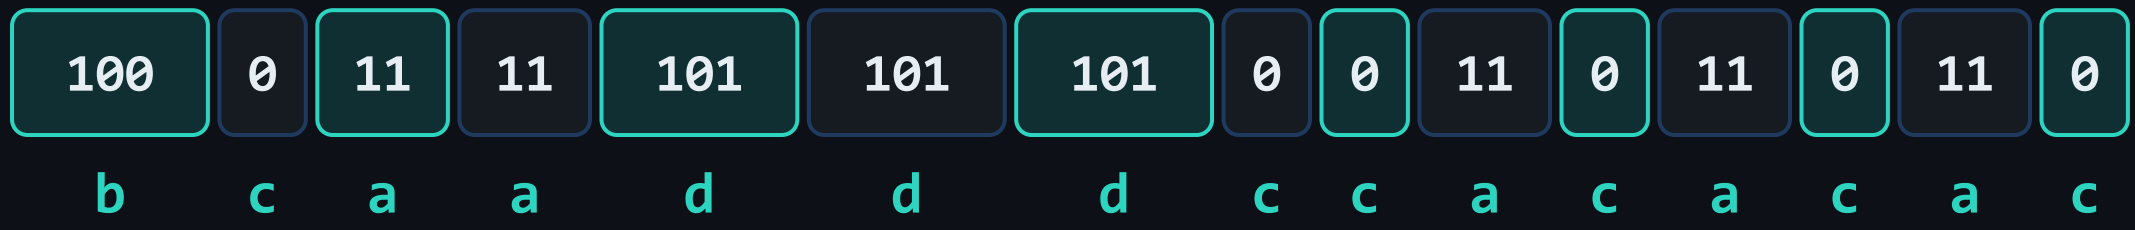


Símbolo	Frecuencia	Código
a	5	11
b	1	100
c	6	0
d	3	101

0 a la izquierda y **1** a la derecha. Los símbolos frecuentes quedan cerca de la raíz y reciben códigos más cortos.

Comprimir el texto

bcaadddccacacac → 28 bits





El tamaño de la tabla de conversión también cuenta como parte del archivo comprimido.

Descomprimir

1

Leer los bits

La cadena comprimida se trata como un stream de datos.

2

Recorrer el árbol

Cada bit baja un nivel: 0 a la izquierda, 1 a la derecha.

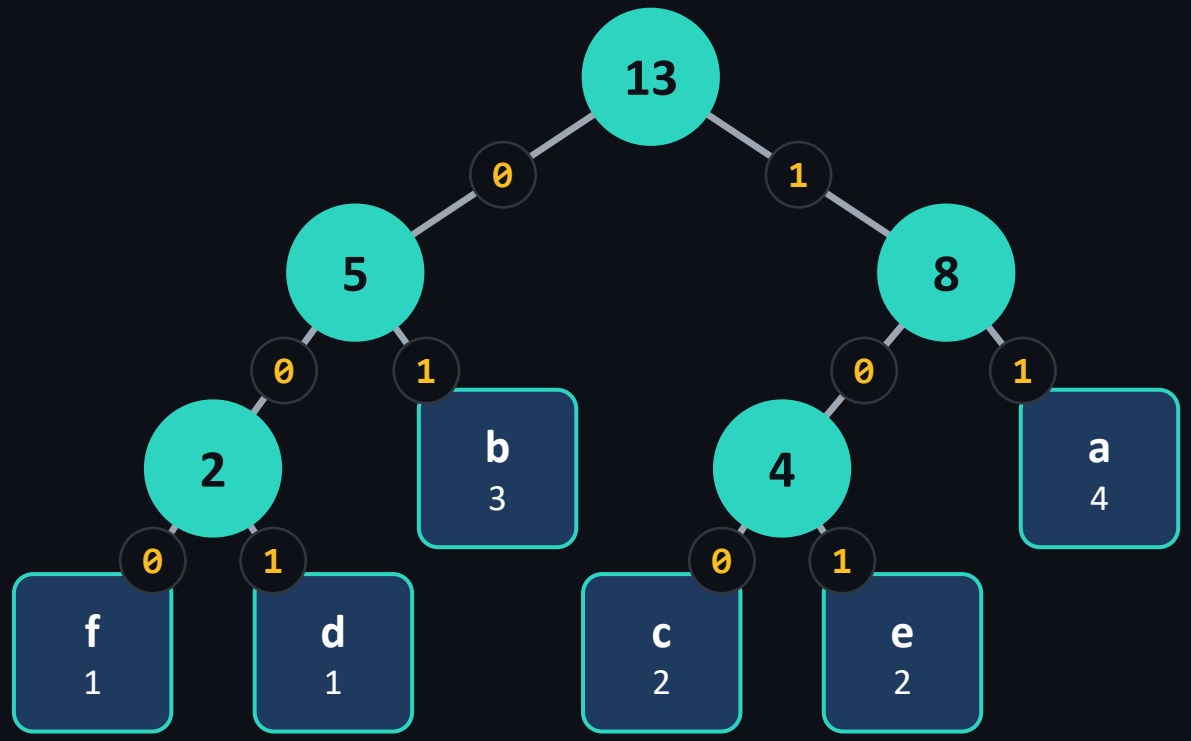
3

Emitir el símbolo

Al llegar a una hoja se emite el símbolo y se vuelve a la raíz.

Ejemplo: `100` → b, `0` → c, `11` → a, `11` → a, `101` → d, y así hasta el final.

Ejercicio resuelto: comprimir «abfabcaecedba»



Símbolo	Frecuencia	Código
a	4	11
b	3	01
c	2	100
d	1	001
e	2	101
f	1	000

Resultado: `1101000110110011101100101001011 1` = **32 bits**; en ASCII serían 13 × 8 = 104 bits.

Ejercicio resuelto: decodificar 011010110000

Secuencia comprimida: 011010110000



Tabla de conversión

A = 010	B = 10	C = 011	D = 0001	E = 0000	F = 11	G = 001

Cómo leer: bit a bit; al completar un código, emita su símbolo. Ningún código es prefijo de otro.

// entropía y límite de shannon

Entropía de Shannon

Definición

Para una fuente cuyos símbolos aparecen con probabilidad `p_i`:

$$H = -\Sigma\ p_i \cdot \log2(p_i)$$

*H se mide en bits por símbolo: es la cantidad promedio **mínima** de bits para representar la fuente sin pérdida.*

Intuición

- Símbolo muy probable: aporta **poca** información
- Símbolo poco probable: aporta **mucha** información
- H es **máxima** si todos son equiprobables y **mínima** si un símbolo domina

// entropía y límite de shannon

Teorema de codificación de la fuente

Shannon: límite inferior

Ningún código sin pérdida símbolo a símbolo usa, en promedio, menos de H bits.

$$L \geq H$$

L = longitud media de código (promedio ponderado por frecuencia).

vs

Huffman: óptimo

Óptimo entre los códigos prefijo, pero usa un número entero de bits por símbolo.

$$H \leq L < H + 1$$

Redundancia = L − H: nunca supera 1 bit por símbolo.

> Si las probabilidades no son potencias de 2, Huffman queda por encima de H. La **codificación aritmética** y por rangos se acercan más al límite.

Ejemplo numérico: Huffman alcanza la entropía

Símbolo	p	log2(p)	-p · log2(p)	Código Huffman	Bits
A	1/2 = 0.5	-1	0.500	0	1
B	1/4 = 0.25	-2	0.500	10	2
C	1/8 = 0.125	-3	0.375	110	3
D	1/8 = 0.125	-3	0.375	111	3

H = 0.5 + 0.5 + 0.375 + 0.375 = **1.75** bits/símbolo

L = 0.5·1 + 0.25·2 + 0.125·3 + 0.125·3 = **1.75** bits/símbolo

// codificación aritmética

Más allá de Huffman: codificación aritmética

Otra forma de acercarse al límite de Shannon, sin códigos de longitud entera.

Un solo número

Todo el mensaje se convierte en un número n con $0 \leq n < 1$.

Subintervalos

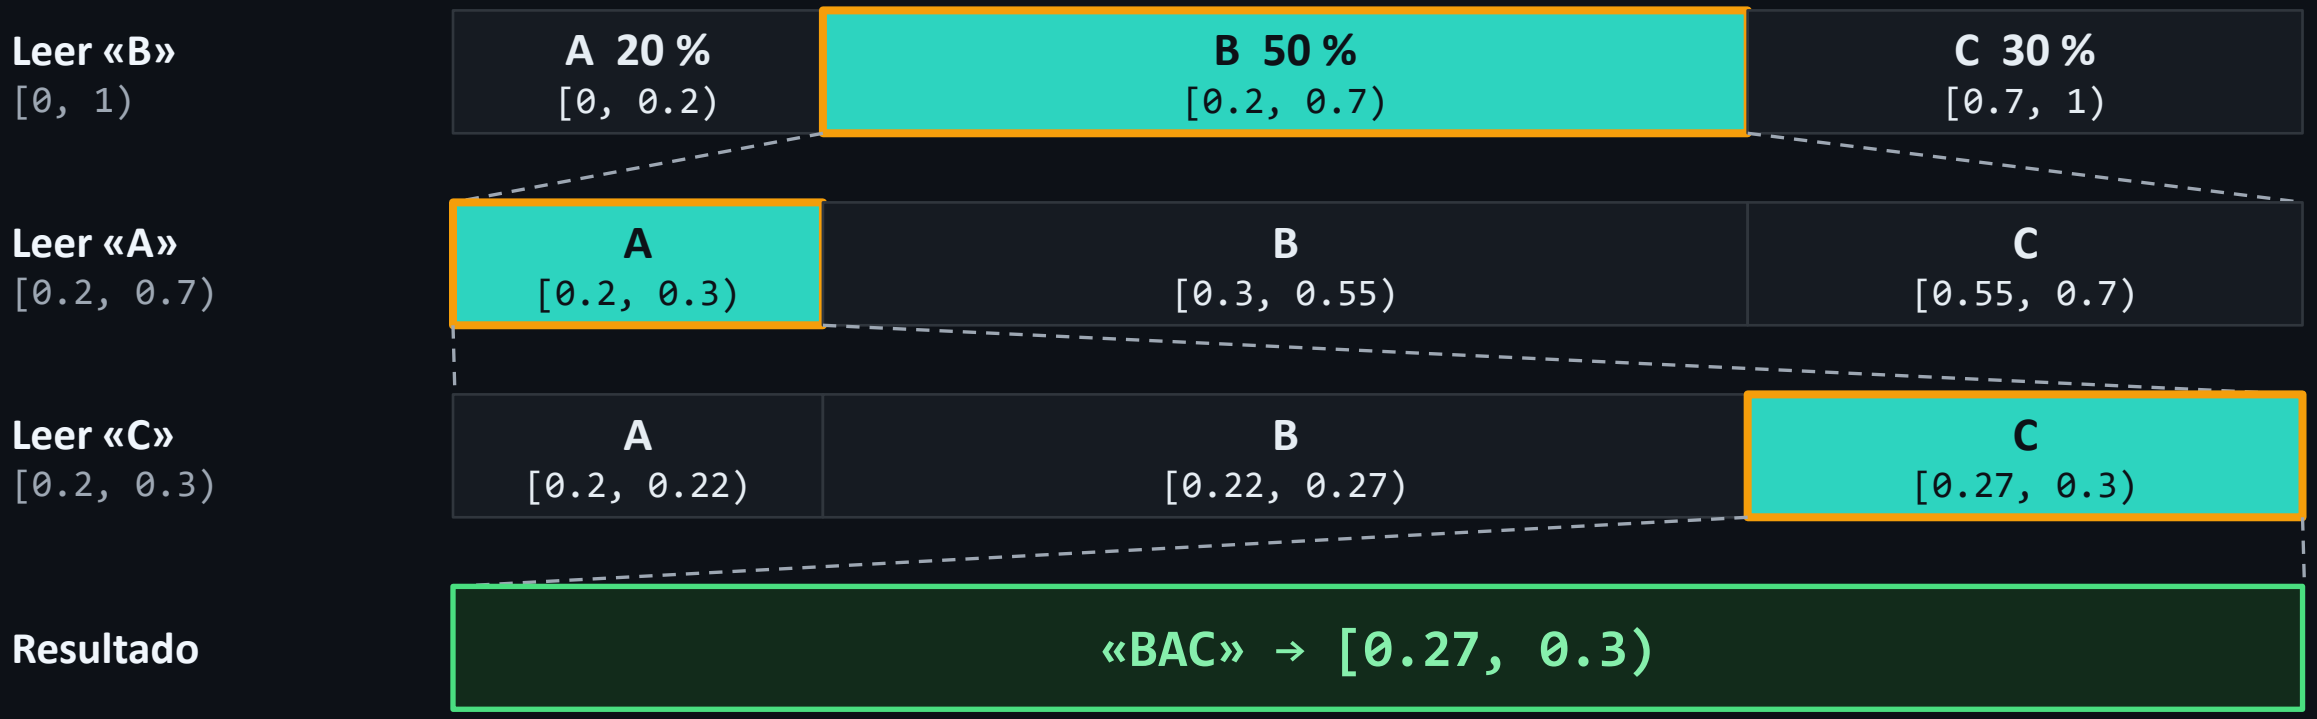
[0, 1) se divide según las probabilidades; cada símbolo reduce el intervalo.

Sin bits enteros

No exige un número entero de bits por símbolo: puede acercarse a H.

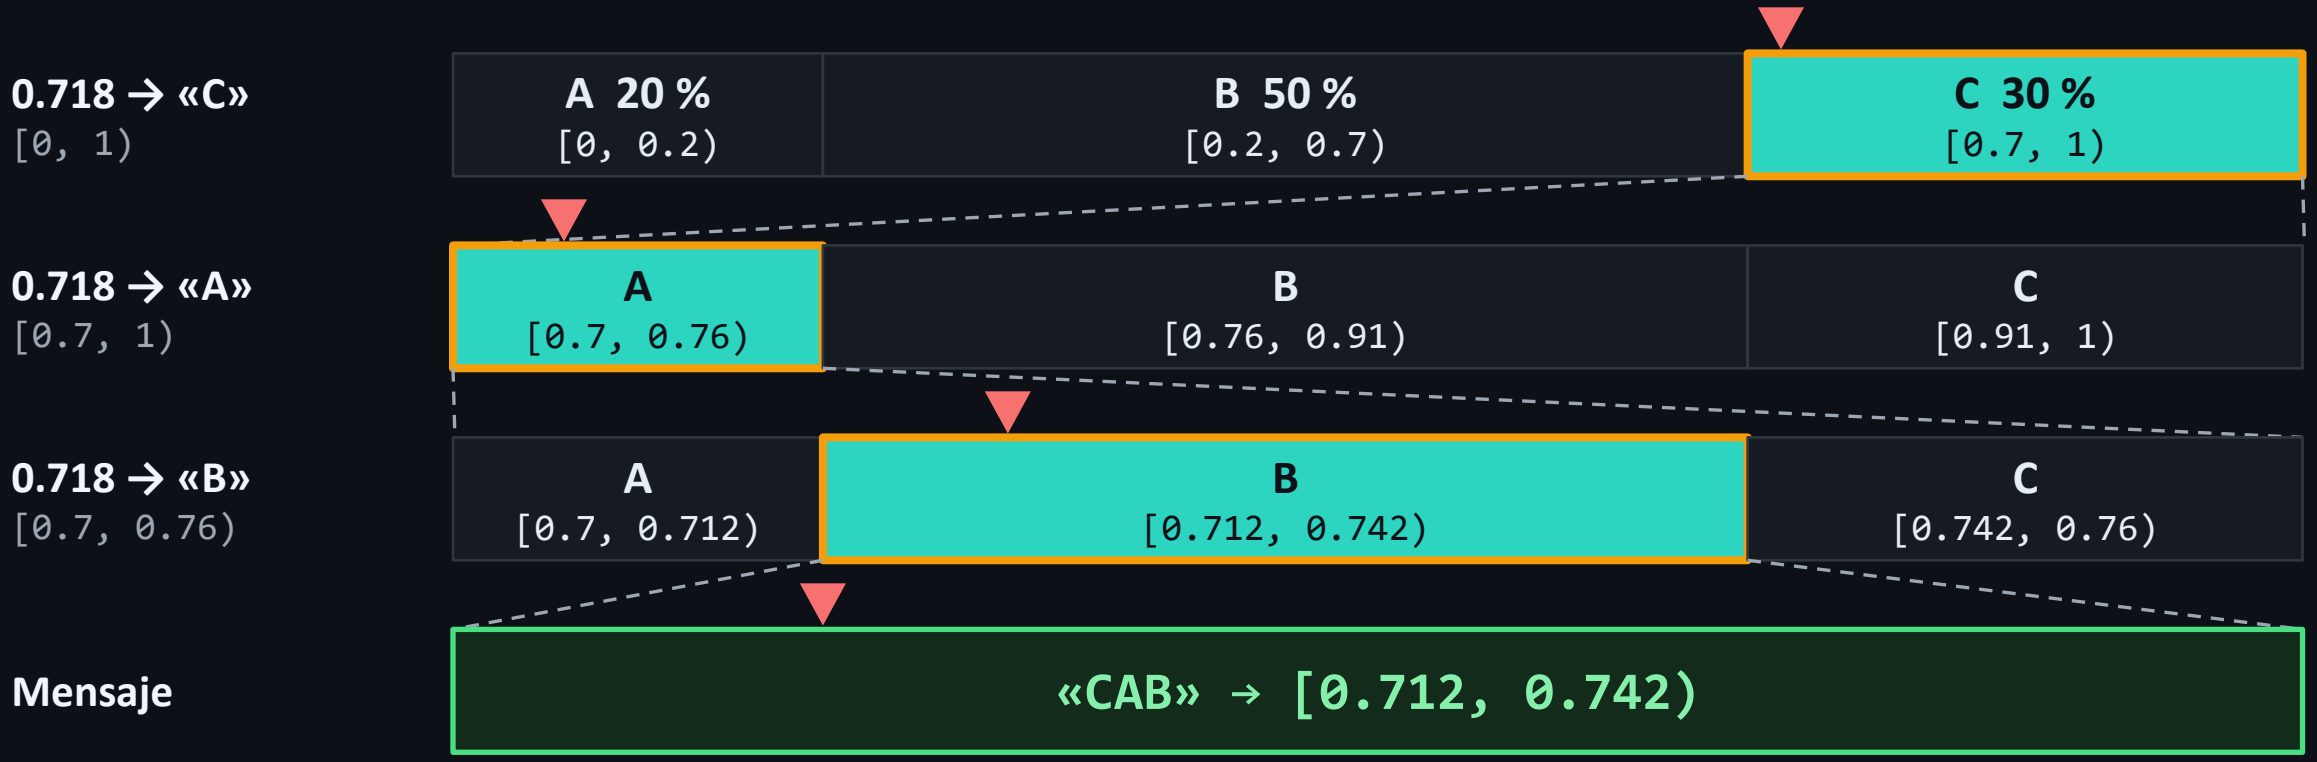
Los símbolos **frecuentes** reducen poco el intervalo, así que cuestan menos bits. Se usa en compresión con y sin pérdida.

Ejemplo: codificar «BAC»



Cualquier número de [0.27, 0.3) representa «BAC», por ejemplo **0.28**. Los intervalos son semiabiertos: incluyen el extremo izquierdo y no el derecho.

Decodificar 0.718 y evaluar el método



Ventajas: flexible con cualquier modelo de probabilidades; casi óptima en la práctica.

Desventaja: lenta: requiere multiplicaciones y divisiones por cada símbolo.

// lz77

LZ77: ventana deslizante

Reemplaza secuencias repetidas por referencias anteriores: una tripleta (o, l, c) por paso.

o

Offset

Cuántos caracteres hacia atrás está la secuencia que coincide.

l

Length

Longitud de la secuencia que coincide.

c

Carácter

El siguiente carácter, el que no coincide.

> La ventana tiene un **diccionario** (ya procesado) y un **buffer** (por procesar), ambos de tamaño fijo. En cada paso se busca la secuencia **más larga** del diccionario que coincida con el inicio del buffer.

LZ77: ejemplo paso a paso



Resultado: `(0, 0, a) (0, 0, b) (2, 2, c) (4, 3, a) (2, 2, a)`. No se necesita ninguna tabla.

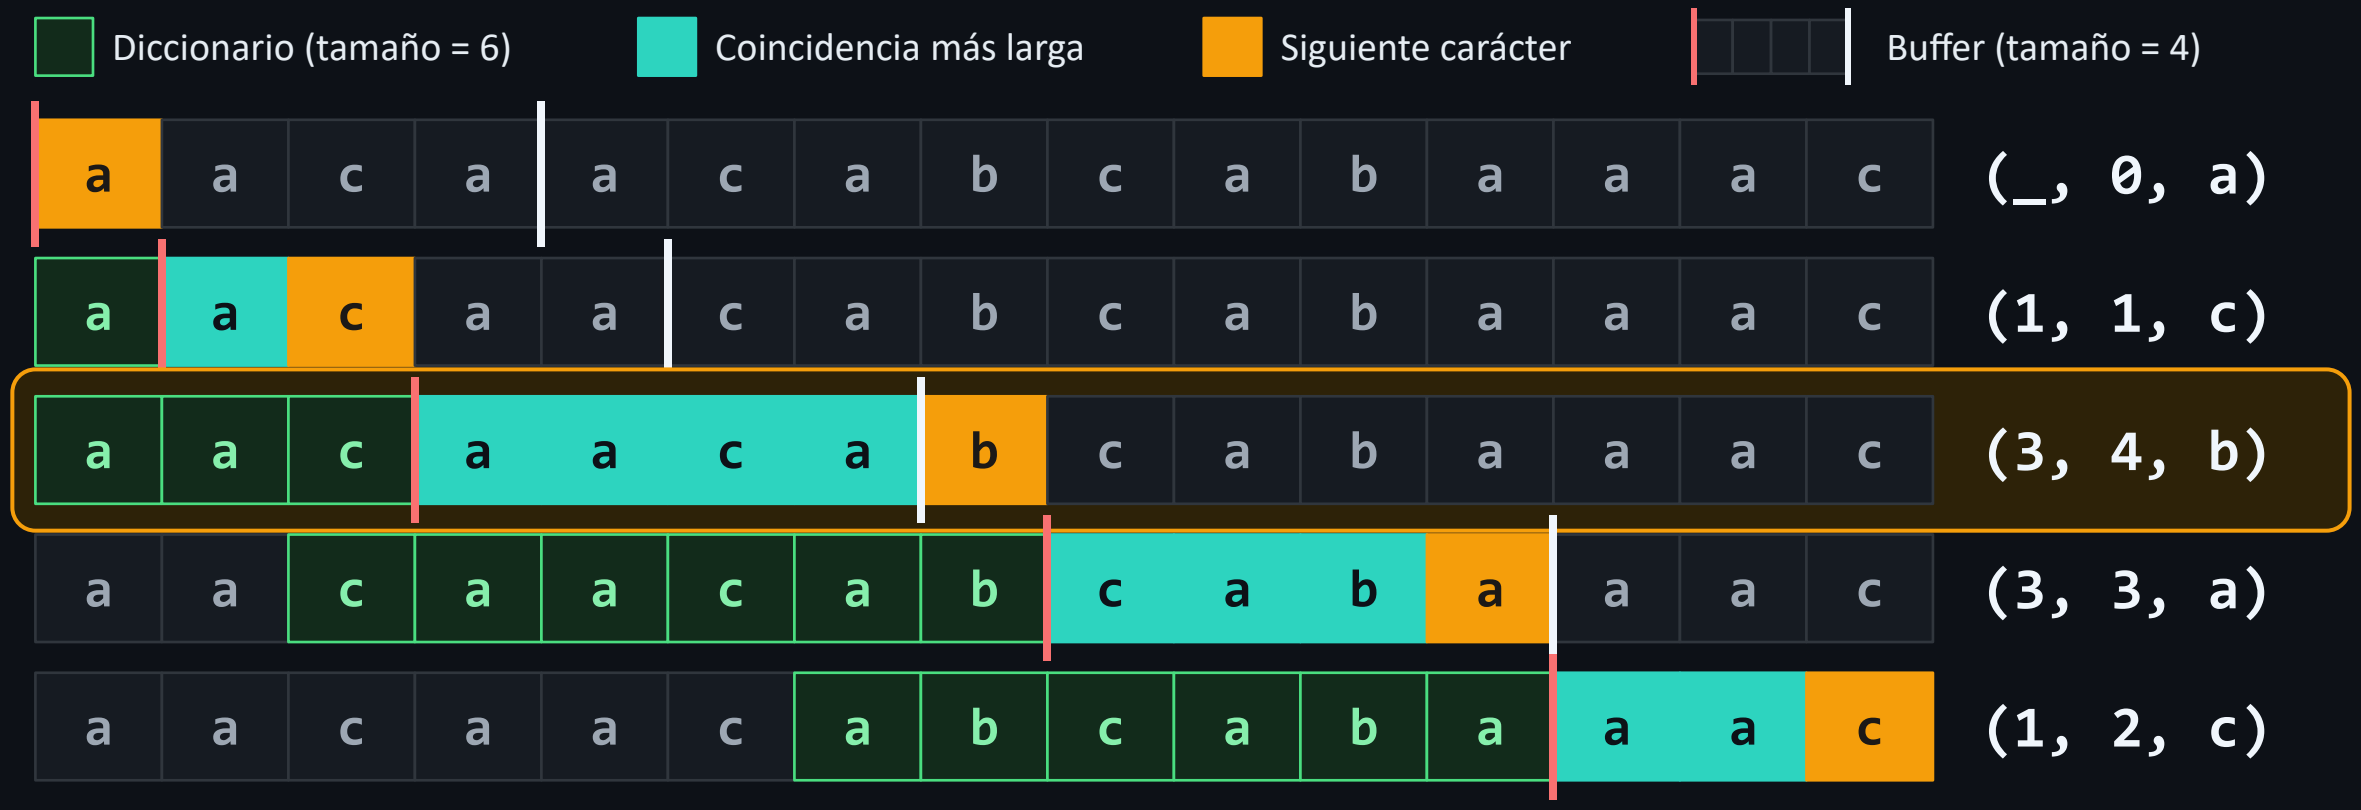
LZ77: descomprimir

Tripleta	Buffer resultante
(0, 0, a)	a
(0, 0, b)	ab
(2, 2, c)	ababc
(4, 3, a)	ababcbaba
(2, 2, a)	ababcbababaa

Regla: copie `l` caracteres desde `o` posiciones atrás y agregue `c`.

Ventaja: no requiere una pasada previa ni una tabla: sirve para comprimir un stream.

LZ77: ¿por qué 4 coincidencias?



¿Puede explicar por qué la tripleta (3, 4, b) tiene 4 coincidencias?

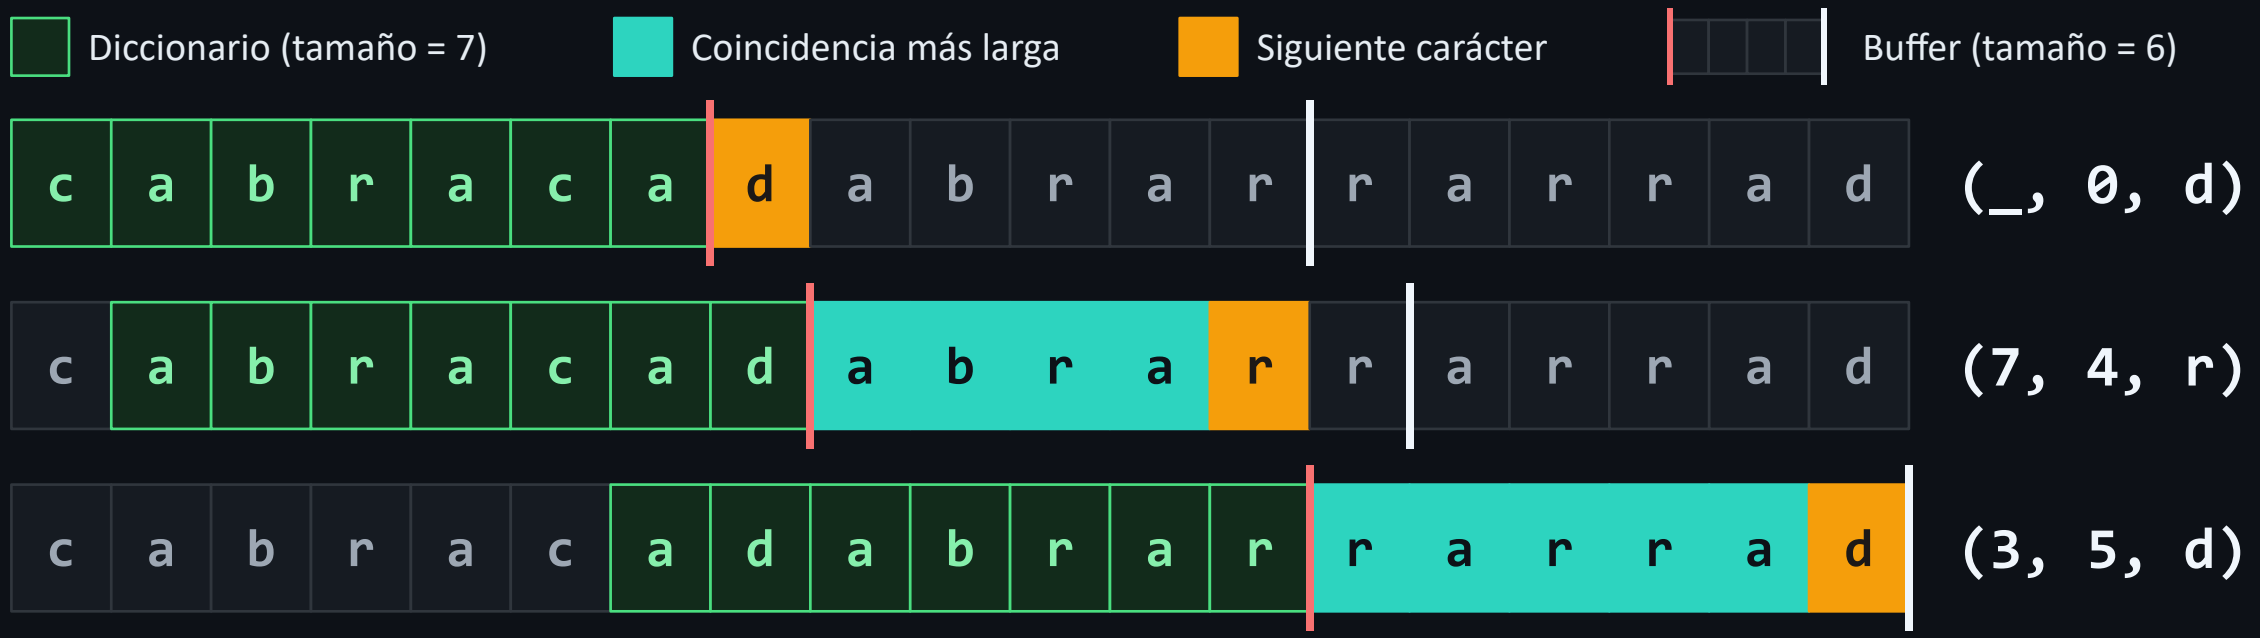
LZ77: descomprimir con coincidencia solapada

Tripleta	Se copia	Buffer resultante
(_, 0, a)	nada	a
(1, 1, c)	a	aac
(3, 4, b)	aaca	aacaacab
(3, 3, a)	cab	aacaacabcaba
(1, 2, c)	aa	aacaacabcabaaac

Solapada: en `(3, 4, b)` el buffer solo tiene 3 caracteres, pero se copian 4: la 4.ª «a» es la que se acaba de copiar.

Regla: copie **carácter por carácter** `l` caracteres desde `o` posiciones atrás y agregue `c`.

LZ77 con diccionario inicial



`(7, 4, r)`: retroceder 7, copiar «abra» y agregar «r». `(3, 5, d)`: copiar «rarra», que se solapa con el buffer, y agregar «d».

Con el diccionario inicial «cabraca»: tripletas (_, 0, d), (7, 4, r) y (3, 5, d).

// lz78

LZ78: diccionario explícito

Lempel y Ziv, 1978: construye un diccionario en lugar de usar una ventana deslizante.

Diccionario explícito

Se construye de forma incremental con un trie para guardar los prefijos conocidos.

Sin ventana

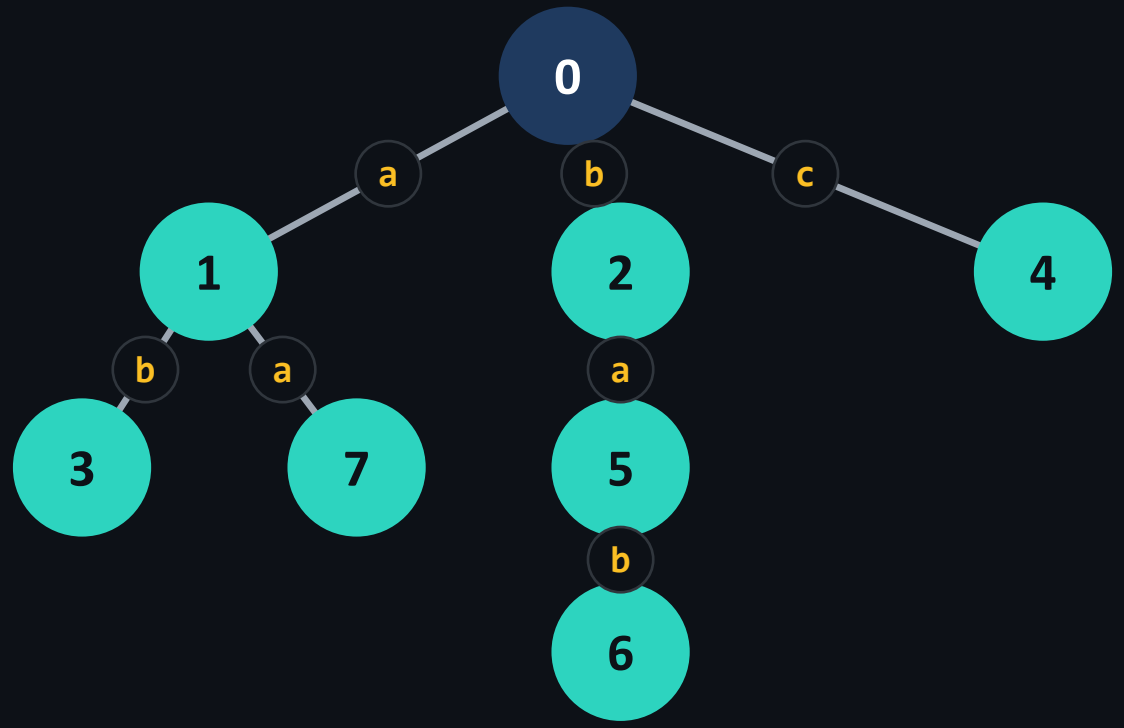
Evita la parametrización que LZ77 requiere para optimizar su desempeño.

Tupla (o, c)i

o: nodo padre · c: carácter nuevo · i: índice del nodo actual.

> El **trie** es el mismo TDA que vimos en la lección de Estructuras de Datos Jerárquicas (CE-1103).

LZ78: el trie y las tuplas



Tupla	Cadena
(0,a)1	a
(0,b)2	b
(1,b)3	ab
(0,c)4	c
(2,a)5	ba
(5,b)6	bab
(1,a)7	aa

Cadena a b a b c b a b a b a a. Descomprimir: desde cada nodo se recorre hasta la raíz. Resultado: ababcbababaa.

// lz78

LZ78: pseudocódigo y fin de la entrada

Compresión

```
Diccionario = solo la cadena vacía (índice 0)
P = cadena vacía
MIENTRAS no sea el fin de la entrada
    C = siguiente carácter
    SI P + C está en el diccionario
        P = P + C
    SINO
        emitir (índice de P, C)
        agregar P + C al diccionario
        P = cadena vacía
FIN MIENTRAS
SI P no es la cadena vacía
    emitir (índice de P, EOF)
```

P · frase actual

La frase conocida que se va reconociendo; vuelve a quedar vacía tras cada tupla.

(índice, EOF)

Si la entrada termina dentro de una frase conocida, no hay carácter nuevo: se emite su índice y EOF.

// lzw

LZW: la mejora de LZ78

Terry Welch, 1984. Muy usado en formatos de archivo como GIF y TIFF.

Tabla de códigos

Los códigos 0 a 255 representan los caracteres ASCII.

Secuencias nuevas

Identifica secuencias repetidas y les crea un código nuevo.

Salida

Emite únicamente códigos de la tabla.

La tabla **no viaja** con el archivo: al descomprimir se **reconstruye** a partir de la tabla inicial (0 a 255).

LZW: pseudocódigo

Compresión

```
Inicializar la tabla con cadenas de un carácter
P = primer carácter de la entrada
MIENTRAS no sea el fin de la entrada
    C = siguiente carácter
    SI P + C está en la tabla
        P = P + C
    SINO
        emitir el código de P
        agregar P + C a la tabla
        P = C
FIN MIENTRAS
emitir el código de P
```

P · prefijo

La cadena reconocida hasta ahora.

C · carácter

El siguiente carácter de la entrada.

LZW: ejemplo con la cadena abacabaca

P	C	P + C	¿Está en la tabla?	Salida	Nuevo código
a	b	ab	No	97	ab = 256
b	a	ba	No	98	ba = 257
a	c	ac	No	97	ac = 258
c	a	ca	No	99	ca = 259
a	b	ab	Sí	—	—
ab	a	aba	No	256	aba = 260
a	c	ac	Sí	—	—
ac	a	aca	No	258	aca = 261
a	—	—	Fin de la entrada	97	—

Salida: 97 98 97 99 256 258 97. Tabla inicial: a = 97, b = 98, c = 99.

LZW: descomprimir

Códigos generados

97	98	97	99	256	258	97
a	b	a	c	ab	ac	a

El decodificador reconstruye la tabla: código nuevo = cadena anterior + 1.er carácter de la actual

- **ab = 256 (a + b)**
- **ba = 257 (b + a)**
- **ac = 258 (a + c)**
- **ca = 259 (c + a)**
- **aba = 260 (ab + a)**
- **aca = 261 (ac + a)**

> La tabla **no viaja** con el archivo: se reconstruye desde la tabla inicial mientras se leen los códigos. Resultado: `a b a c ab ac a` = `abacabaca`.

// práctica

Practique: LZ78, LZW y codificación aritmética

Resuelva cada caso y compare su respuesta con un compañero:

A

LZ78

Comprima `abracadabrarabarabara` y escriba el diccionario resultante.

B

LZW

Con la tabla inicial `a`, `c`, `w` (97, 99 y 119), comprima `waccawacca`.

C

Aritmética

Con A = 20 %, B = 50 % y C = 30 %: ¿qué intervalo representa «CAB»? ¿Contiene 0.718?

Verifique: descomprima su resultado y compruebe que obtiene la cadena original.

// comparación

Resumen comparativo

	Año	Estructura	Diccionario o tabla	Característica	Se usa en
Huffman	1952	Árbol binario	Tabla de códigos guardada en el archivo	Códigos de longitud variable según la frecuencia	JPEG; PNG y ZIP (Deflate)
LZ77	1977	Ventana deslizante	Ninguna: tripletas (o, l, c)	No requiere pasada previa	gzip, ZIP y PNG (Deflate)
LZ78	1978	Trie	Diccionario explícito que crece	Sin ventana que parametrizar	Base de LZW
LZW	1984	Tabla de códigos	Tabla inicial 0 a 255; no viaja en el archivo	La tabla se reconstruye al descomprimir	GIF y TIFF

Los cuatro son **sin pérdida**: los datos originales se recuperan exactamente.

Deflate = LZ77 + Huffman: lo usan ZIP, gzip y PNG.

// cierre

Resumen

- Comprimir es usar menos bits: **con pérdida** (irreversible) o **sin pérdida** (reversible).
- **Huffman** da códigos más cortos a los símbolos más frecuentes mediante un árbol binario.
- La **entropía** H es el límite: $L \geq H$, y Huffman cumple $H \leq L < H + 1$.
- La **codificación aritmética** codifica todo el mensaje como un solo número.
- **LZ77** usa una ventana y tripletas (o, l, c); **LZ78**, un trie; **LZW**, una tabla de códigos.
- La tabla de **Huffman** viaja en el archivo; los **LZ** construyen su diccionario sobre la marcha.

// cierre

Referencias

- https://www.geeksforgeeks.org/what-are-data-compression-techniques/
- https://www.programiz.com/dsa/huffman-coding
- https://hackernoon.com/how-lz77-data-compression-works-yk113te0
- https://hackernoon.com/how-lz78-compression-algorithm-works-x7103tlm
- https://www.geeksforgeeks.org/lzw-lempel-ziv-welch-compression-technique/